

## Laborator 8

Algoritmul de învățare Widrow-Hoff bazat pe regula  $\mu$ -LMS (*least mean squares*) antrenează ponderile unui perceptron cu funcția de transfer liniară (funcția ***purelin*** în Matlab) pentru a minimiza funcția criteriu  $J$  dată de suma pătratelor erorilor. Pentru mulțimea de antrenare  $S = \{(\mathbf{x}^1, d^1), (\mathbf{x}^2, d^2), \dots, (\mathbf{x}^m, d^m)\}$ , algoritmul încearcă să găsească  $\mathbf{w}^*$  și  $b^*$  astfel încât să minimizeze:

$$J(\mathbf{w}, b) = \frac{1}{2} \sum_{i=1}^m (d^i - y^i)^2, \text{ unde } y^i = \mathbf{w}^T \mathbf{x}^i + b.$$

Funcția criteriu  $J$  definește o suprafață de eroare ce ia forma unui paraboloid convex care are punctul de minim global  $\boldsymbol{\beta} = \begin{pmatrix} b^* \\ \mathbf{w}^* \end{pmatrix}$  soluție a ecuației:

$$(\boldsymbol{\beta}^T X - \mathbf{d}^T)(\boldsymbol{\beta}^T X - \mathbf{d}^T)^T = 0$$

Rezolvând ecuația de mai sus (detalii la seminar) se obține soluția în formă explicită:

$$\boldsymbol{\beta} = \begin{pmatrix} b^* \\ \mathbf{w}^* \end{pmatrix} = (XX^T)^{-1}X\mathbf{d},$$

unde  $X$  este matricea cu  $n+1$  linii și  $m$  coloane (exemplele  $\mathbf{x}^i$  sunt vectori coloană cu  $n$  componente), care pe coloana  $i$  are forma  $[1; \mathbf{x}^i]$ , iar  $\mathbf{d} = [d^1 \ d^2 \ \dots \ d^m]^T$ . Vectorul  $\boldsymbol{\beta}$  este soluția problemei de regresie liniară pentru mulțimea  $S$ .

O alternativă la calculul soluției optime  $\boldsymbol{\beta} = \begin{pmatrix} b^* \\ \mathbf{w}^* \end{pmatrix}$  este minimizarea funcției criteriu  $J$  (este convexă) folosind algoritmul de coborâre pe gradient. Obținem regula de învățare batch dată de:

$$\mathbf{w}^{k+1} = \mathbf{w}^k + \mu \sum_{i=1}^m (d^i - y^i) \mathbf{x}^i$$

$$b^{k+1} = b^k + \mu \sum_{i=1}^m (d^i - y^i)$$

Se demonstrează că pentru valori mici ale ratei de învățare  $\mu$  (spre exemplu 0.005) algoritmul de învățare converge la soluția dată de  $\beta$ . Soluția  $\beta$  pe care o obținem minimizează  $J$  rezolvând optim problema de regresie liniară multidimensională pe mulțimea de antrenare  $S$ . Totuși  $\beta$  nu optimizează rata de misclasare, ceea ce înseamnă că soluția obținută s-ar putea să nu separe bine clasele.

Fie mulțimea de antrenare este  $S = \{([-2,2]^T, -1), ([-2,3]^T, -1), ([-1,1]^T, -1), ([-1,4]^T, -1), ([0,0]^T, -1), ([0,1]^T, -1), ([0,2]^T, -1), ([0,3]^T, -1), ([1,0]^T, +1), ([1,1]^T, -1), ([2,1]^T, +1), ([2,2]^T, -1), ([3,-1]^T, +1), ([3,0]^T, +1), ([3,1]^T, +1), ([3,2]^T, +1), ([4,-2]^T, +1), ([4,1]^T, +1), ([5,-1]^T, +1), ([5,0]^T, +1)\}$ . Realizați următoarele:

1. reprezentați punctele mulțimii de antrenare  $S$  în plan, asociind markere/culori diferite pentru punctele din cele două clase;
2. aflați soluția  $\beta = \begin{pmatrix} b^* \\ \mathbf{w}^* \end{pmatrix}$  a ecuației în formă explicită de mai sus și reprezentați dreapta definită de această soluție;
3. implementați algoritmul de învățare Widrow-Hoff varianta batch construind o rețea cu un perceptron cu funcția de transfer *purelin*, funcția de antrenare *trainb* (antrenare de tip batch), regula de învățare pentru ponderi și bias *learnwh* (Widrow-Hoff), rata de învățare 0.005, numărul de epoci 1000. Setati câmpurile corespunzătoare acestor proprietăți într-un obiect Matlab de tip *network* și rulați antrenarea. Reprezentați dreapta de separare obținută.
4. putem înțelege mai bine semnificația soluției  $\beta = \begin{pmatrix} b^* \\ \mathbf{w}^* \end{pmatrix}$  reprezentând exemplele din mulțimea de antrenare în spațiul 3D asociat (adică primul exemplu de antrenare  $([-2, 2]^T, -1)$  îl vedem ca punctul 3D  $(-2, 2, -1)$ ) folosind codul Matlab de mai jos:

```
P = [-2 -2 -1 -1 0 0 0 0 1 1 2 2 3 3 3 3 4 4 5 5; ...
      2 3 1 4 0 1 2 3 0 1 1 2 -1 0 1 2 -2 1 -1 0; ...
      -1 -1 -1 -1 -1 -1 -1 -1 1 1 -1 1 -1 1 1 1 1 1 1 1];
figure, plot3(P(1,:), P(2,:), P(3,:), 'sr'); hold on;
[x y] = meshgrid(-5:0.5:5);
z = beta(1) + beta(2)*x + beta(3)*y;
figure(gcf), mesh(x, y, z);
```

Soluția  $\beta = \begin{pmatrix} b^* \\ \mathbf{w}^* \end{pmatrix}$  definește planul în 3D care are proprietatea că

predicțiile realizate sunt cele mai apropiate de etichete (avem în acest caz o problemă de regresie).

Pentru exemplul anterior nu putem vizualiza suprafața de eroare definită de funcția criteriu  $J$  întrucât aceasta depinde de 3 parametri (2 parametri de la  $\mathbf{w}$ , 1 parametru de la  $\mathbf{b}$ ). Pentru a putea vizualiza suprafața de eroare precum și evoluția soluției curente  $\mathbf{w}^k$  vom restricționa problema numai la 2 parametri (cei dați de  $\mathbf{w}$ ), setând o rețea fără bias cu comanda `net.biasConnect = 0`.

5. determinați soluția  $\mathbf{w}^*$  pentru cazul în care nu există bias ( $X$  este acum o matrice cu  $m$  linii și  $n$  coloane, linia  $i$  conține exemplul  $\mathbf{x}^i$ );
6. implementați algoritmul de învățare Widrow-Hoff varianta batch pentru cazul unei rețele fără bias, păstrând aceiași parametri ca la 3. Reprezentați dreapta de separare obținută.
7. reprezentați paraboloidul dat de funcția criteriu  $J(\mathbf{w})$  pe domeniul  $\mathbf{w} = [w_1, w_2] \in [-0.7, 0.7] \times [-0.7, 0.7]$  folosind funcțiile Matlab *meshgrid* și *surf*.
8. modificați codul Matlab pentru punctul anterior 6 astfel încât să memorați valorile soluției curente  $\mathbf{w}^k$  la epoca  $k$ . Plotați apoi folosind funcția Matlab *plot3* punctele de forma  $(\mathbf{w}^k, J(\mathbf{w}^k))$  observând cum se modifică la fiecare pas soluția curentă  $\mathbf{w}^k$  și valoarea funcției criteriu  $J$ .
9. reluați punctele 6, 7 și 8 pentru algoritmul de învățare Widrow-Hoff varianta incrementală cu prezentarea aleatoare (funcția *trainr*) a exemplilor la fiecare epocă.
10. reluați punctele 6, 7 și 8 pentru algoritmul de învățare Widrow-Hoff varianta incrementală cu prezentarea ciclică (funcția *trainc*) a exemplilor la fiecare epocă.
11. studiați convergența învățării în cele 3 cazuri (batch, incrementală cu prezentarea aleatoare a exemplilor, incrementală cu prezentarea deterministă a exemplilor) realizând un grafic cu diferența  $\|\mathbf{w}^k - \mathbf{w}^*\|$  după fiecare epocă  $k$ .