

Vedere Artificială - Tema 4

Antrenarea dicționarilor pentru reprezentări rare. Aplicații la eliminarea de zgomot și restaurarea în imagini

Obiectiv:

Scopul acestei teme este implementarea și testarea algoritmilor de eliminare de zgomot (denoising) și restaurare (inpainting) într-o imagine pe baza antrenării unui dicționar pentru reprezentări rare.

Funcțiile Matlab care vă vor ajuta la implementarea temei sunt în directorul *cod*; imaginile pe care le veți folosi sunt în directorul *data*.

Pentru a înțelege tema consultați slide-urile de la curs. Toate detaliile legate de predarea temei le găsiți la sfârșitul acestui document.

Punct de pornire

Scriptul *test_denoising_distinct.m* vă oferă un punct de pornire în implementarea voastră. În acest script se fixează anumite valori pentru parametrii folosiți în implementare:

- dimensiunea p în pixeli a unui patch (petec) $p \times p$;
- nivelul s de sparsitate;
- numărul N de patch-uri folosite la învățarea dicționarului D ;
- dimensiunea n a dicționarului D ce urmează a se învăța;
- numărul de iterații K folosit la învățarea dicționarului D ;
- deviația standard σ folosită la generarea de zgomot.

Dicționarul D se inițializează aleator și se normalizează, fiecare din cele n coloane este un vector de medie 0 și normă (lungime) 1. Dicționarul D este redundant, conține mult mai multe coloane decât cele $m = p \times p$ coloane necesare unei baze din \mathbb{R}^m .



Figura 1: Eliminarea de zgomot. (a) Imaginea inițială. (b) Imaginea cu zgomot. (c) Rezultatul obținut cu patch-uri distincte, care nu se suprapun; (d) Rezultatul obținut cu patch-uri care se suprapun.

1.1 Eliminarea de zgomot cu patch-uri distincte

Tratăm mai întâi operația de eliminare de zgomot dintr-o imagine (Figura 1a) folosind patch-uri distincte, care nu se suprapun. Alterăm conținutul imaginii inițiale I prin modificarea valorii fiecărui pixel. Adăugăm la fiecare pixel un zgomot (un scalar) cu distribuție normală de medie 0 și deviație standard σ . Obținem astfel imaginea *Inoisy* (Figura 1b).

Eliminarea de zgomot presupune învățarea unui dicționar D și a reprezentării rare corespunzătoare, matricea X , care să reprezinte cât mai bine datele inițiale Y (fiecare coloană din Y conține un patch $p \times p$ vectorizat). Intuiția este că dicționarul D învățat va putea reprezenta numai patternuri recurente din imagine, neputând învăța zgomotul. Astfel, la reconstrucția datelor inițiale din Y pe baza dicționarului D învățat se elimină zgomotul.




Figura 2: Eliminare de zgomot cu patch-uri distincte (a) vs patch-uri suprapuse (b).

Învățăm reprezentarea rară X și dicționarul D iterând de un număr de K ori algoritmi OMP și $K-SVD$ predați la curs. Funcția *omp* găsește reprezentarea rară, matricea X , a semnalelor Y (pe fiecare coloană a matricei Y sunt toți pixelii dintr-un patch $p \times p$) pe baza dicționarului curent D și a nivelului de sparsitate s . Funcția *omp* este furnizată în arhiva cu materiale. Ea conține apelul către executabilul *omp_mex*, obținut prin compilarea unui fișier sursă în limbajul C care implementează algoritmul OMP prezentat la curs. Timpul de calcul este mult redus prin apelarea fișierului executabil din C decât implementarea în Matlab a unei funcții asemănătoare. Similar, funcția *aksvd*, furnizată în arhiva cu materiale, implementează algoritmul $K-SVD$, actualizând dicționarul D și reprezentarea corespunzătoare X .

Urmând indicațiile de la curs, obținem în final reprezentarea X_c și patch-urile reconstruite Y_c . Pe baza lor veți reconstrui imaginea I_c (Figura 1c) care nu ar trebui să conțină zgomot.

- Completați codul Matlab din scriptul *test_denoising_distinct.m* pentru a reconstrui imaginea din patch-urile obținute. Ar trebui să obțineți un rezultat similar cu cel din Figura 1c.

1.2 Eliminarea de zgomot cu patch-uri suprapuse

Rezultatul obținut anterior (Figura 1c, o parte din imagine este prezentată în zoom în Figura 2a) arată că imaginea reconstruită este alcătuită din blocuri. Pentru eliminarea acestui artefact veți procesa patch-uri care se suprapun, modificând în cod partea de extragere a acestor patch-uri din imaginea cu zgomot. Secvența de cod pentru învățarea dicționarului D și a reprezentării rare X_c rămâne la fel. Reconstruiți imaginea finală (Figura 1d, o parte din imagine este prezentată în zoom în Figura 2b) astfel încât fiecare pixel va fi media valorilor diferite obținute în patch-urile în care apare.




Figura 3: Restaurarea unei imagini. Imaginea inițială vs. imaginea cu pixeli lipsă vs. imaginea restaurată.

- Scrieți scriptul *test_denoising_overlapping.m* care implementează această metodă.

1.3 Inpainting

Putem folosi învățarea unui dicționar și aflarea reprezentării rare corespunzătoare la restaurarea unei imagini din care lipsesc foarte mulți pixeli (Figura 3). Scriptul *test_inpainting.m* elimină din imaginea inițială 70% din pixelii ei (pixelii eliminați sunt reprezentați cu negru). Totuși, putem învăța dicționarul D folosind un cod asemănător ca la eliminarea de zgomot, utilizând matricea (masca) care reține pozițiile pixelilor prezenți în imaginea pe care o procesăm. În această temă, restaurarea imaginii se realizează folosind patch-uri distincte, care nu se suprapun.

- Completați codul Matlab al scriptului *test_inpainting.n* astfel încât pe baza dicționarului învățat să găsiți reprezentarea rară a imaginii cu pixeli lipsă și să reconstruiți imaginea inițială. Rezultatul vostru ar trebui să arate ca cel din Figura 3.

1.4 Predarea proiectului

Puneți într-o arhivă cu numele *tema4_cod.zip* codul vostru Matlab. Puneți într-un document cu numele *tema4_rezultate.pdf* următoarele:

- imaginea reconstruită pentru toate cele 3 cazuri prezentate: eliminare de zgomot cu patch-uri distincte, eliminare de zgomot cu patch-uri suprapuse, restaurare cu patch-uri distincte.
- Statisticile *psnr* și *ssim* cuantifică cât de similară este imaginea inițială cu cea reconstruită. Valori mai mari ale acestor două statistici indică o similaritate mai mare. Calculați aceste valori în pentru toate cele 3 cazuri, eliminare de zgomot cu patch-uri distincte, eliminare de zgomot cu patch-uri suprapuse, restaurarea imaginii.
- Încercați valori diferite pentru următorii parametri: p - dimensiunea unui patch, N - numărul de patch-uri folosite la învățarea dicționarului D , n - dimensiunea

dicționarului D , σ - deviația standard a zgomotului. Cum influențează fiecare parametru reconstrucția imaginii inițiale? Puteți să vă raportați numai la una dintre cele trei metode prezentate.

Vom puncta tema în felul următor: 1 punct din oficiu, 6 puncte implementarea corectă a eliminării de zgomot (3 puncte pentru fiecare variantă descrisă: eliminare de zgomot cu patch-uri distincte, eliminare de zgomot cu patch-uri suprapuse), 2 puncte restaurarea imaginii, 1 punct prezentarea temei.

Trimiteți cele două fișiere (*tema4_cod.zip* și *tema4_rezultate.pdf*) la adresa de email a lui Bogdan, **bogdan.alexe@fmi.unibuc.ro**.

Termenul limită de predare a proiectului este duminică, 23 decembrie 2018, ora 23:59. Fiecare zi de întârziere în predarea proiectului se penalizează cu 1 punct în minus.